Datos, fuentes y proceso

Documento de trazabilidad: de dónde salen los datos, cómo se han tratado, qué cobertura hay y qué limitaciones debe conocer cualquier persona que continúe el proyecto.

1. Resumen de datos

Métrica	Valor
Equipos	29
DHA	12
DHB	16
Primera Andaluza	1
Perfiles	976
Jugadores	509
Invitados	467
Porteros	75
Posiciones oficiales	175
Posiciones estimadas	801
Imágenes disponibles	976
Bajas registradas	14
Atributos por jugador	37

Distribución por liga

Liga	Perfiles	Posiciones oficiales	Posiciones estimadas
DHA	412	103	309
DHB	536	68	468
Primera Andaluza	28	4	24
Total	**976**	**175**	**801**

Distribución por posición

Posición base	Perfiles
Defensa	400
Delantero	253
Medio	242
Portero	75
Medio/Delantero	4
Defensa/Medio	2

Subposición estimada

Subposición	Perfiles
Central	249
Lateral	151
Medio	242
Delantero	253
Portero	75
Polivalente	6

De los 400 defensas, 400 tienen subposición Central o Lateral; **399 perfiles tienen la subposición estimada** porque la fuente solo indicaba “Defensa” o no especificaba el lado.

---

2. Fuentes principales

2.1. RFEH / iSquad

- **Uso:** plantillas, nombres, edades, goles, estado, imágenes, actas.
- **Cobertura:** DHA y DHB 2026-27.
- **Fiabilidad:** alta para datos de competición; media para posiciones (no siempre publica la demarcación).
- **Limitaciones:** los goles de iSquad no distinguen PC, stroke o jugada abierta; no hay asistencias completas; algunas plantillas incluyen invitados.

2.2. Actas oficiales de la RFEH

- **Uso:** porteros y alineaciones.
- **Volumen:** 562 actas procesadas.
- **Cobertura:** 64 perfiles con posición oficial de portero/acta.
- **Fiabilidad:** alta para quién juega y quién es portero; baja para la subposición de los defensas.
- **Limitaciones:** no todas las actas están disponibles; algunas no detallan la posición.

2.3. Webs oficiales de clubes

- **Uso:** posiciones oficiales de jugadores.
- **Clubes:** Atlètic Terrassa, Club Egara, RC Polo, Egara 1935.
- **Cobertura:** 68 perfiles (18 + 33 + 17).
- **Fiabilidad:** alta, pero no todos los clubes publican plantilla con posiciones.
- **Limitaciones:** la información puede quedar desactualizada; algunos clubes solo publican dorsales o nombres.

2.4. Prensa

- **Uso:** posiciones de CD Terrassa.
- **Fuente:** Diari de Terrassa.

- **Cobertura:** 3 perfiles.
- **Fiabilidad:** media-alta; depende de la crónica.
- **Limitaciones:** cobertura puntual.

2.5. Estimación por rol y goles

- **Uso:** completar los 801 perfiles sin posición oficial.
- **Método:** posición base según el rol habitual y el peso goleador dentro del equipo; subposición Central/Lateral según el perfil y el contexto.
- **Fiabilidad:** baja-media; es una aproximación, no un dato oficial.
- **Limitaciones:** un defensa con muchos goles puede parecer delantero; por eso el modelo separa posición y atributos.

2.6. Reglamento y formato

- **RFEH:** Circular 1 2026-27, Reglamento de competiciones, normativa 7-2026.
- **FIH:** *Rules of Hockey*.
- **Uso:** formato de liga, desempates, PC, stroke, faltas, tarjetas y duración.
- **Fiabilidad:** alta.
- **Limitaciones:** las reglas pueden cambiar; hay que contrastar la edición vigente.

2.7. Actas y alineaciones: qué se puede y qué no se puede obtener

- Las **actas oficiales de la RFEH** (562 procesadas) identifican convocados, titulares, porteros, goles, tarjetas y sanciones.
- **No incluyen la posición de los jugadores de campo.** La columna `P/J` solo distingue portero (`P`) y jugador (`J`).
- Por tanto, las actas sirven para confirmar **porteros y alineaciones**, pero no para asignar central, lateral, medio o delantero.
- La **prensa local** a veces menciona posiciones individuales (“el defensa X”, “el delantero Y”) o publica alineaciones por líneas, pero no de forma sistemática para todos los equipos.
- Las **webs de clubes** que publican plantilla con posición son la fuente más fiable. La cobertura se detalla en la sección 4.
- Los **partidos EHL** y las **listas de selección** pueden confirmar posiciones de jugadores internacionales, pero solo de un subconjunto.

2.8. Fuentes conceptuales

- Wikipedia, *Field hockey* y *Penalty corner* (consulta 2026).
- Manuales y artículos de técnica de hockey.
- Videos y análisis de PC, drag flick y stroke.

---

3. Proceso de datos

3.1. Extracción

1. Descarga de plantillas y datos de iSquad/RFEH.
2. Procesamiento de actas para detectar porteros.

3. Revisión de webs oficiales de clubes.
4. Búsqueda de prensa para CD Terrassa.
5. Normalización de nombres, equipos y ligas.

3.2. Normalización

- Nombres en mayúsculas.
- Eliminación de tildes en identificadores internos, pero conservación en pantalla.
- Equipos con nombres de competición.
- Clubes con nombre completo.
- Duplicados de jugadores con distinto perfil (Jugador/Invitado) conservados.
- Imágenes asociadas por `archivo_thumb`.

3.3. Posiciones

- Si hay fuente oficial: se usa la posición oficial.
- Si no: se estima por rol y goles.
- Si la posición es “Defensa” sin lado: se asigna Central o Lateral según perfil y contexto.
- Si hay duda: se marca confianza Baja y `sub_estimada = True`.

3.4. Atributos

- Generación con `build_attributes_v2.py`.
- 37 atributos por jugador.
- Pesos por posición.
- Refuerzo por goles solo en atributos ofensivos.
- Especialistas por equipo.

3.5. Validación

- Comprobación de 976 filas y 29 equipos.
- Comprobación de 75 porteros.
- Revisión de ejemplos:
- Iain Martin McFadden: Central, 73,9, Central constructor.
- Bruno Àvila Gran: Central, 56 goles, 84,2, Muro.
- Pruebas del HTML con Selenium.
- Pruebas del editor y de `localStorage`.

---

4. Cobertura de posiciones

4.1. Por fuente

Fuente	Perfiles	%
Estimada	801	82,1 %
Acta oficial RFEH	64	6,6 %
Web oficial Club Egara	33	3,4 %

Fuente	Perfiles	%
Web oficial Atlètic Terrassa	18	1,8 %
Web oficial RC Polo	17	1,7 %
Prensa (Diari de Terrassa)	6	0,6 %
Mundo Deportivo (selección española 2025)	4	0,4 %
EuroHockey (selección sub-21)	3	0,3 %
Global Sports Archive	2	0,2 %
Diari de Terrassa	2	0,2 %
Canarias7	1	0,1 %
Confederación Argentina de Hockey	1	0,1 %
8SPORTS.es	1	0,1 %
University of Pretoria	1	0,1 %
Deporte de la Isla	19	1,9 %
Deporte Alicante	1	0,1 %
El Castillo de San Fernando	1	0,1 %
Web oficial CD Giner de los Ríos	1	0,1 %
Total	**976**	**100 %**

4.2. Por confianza

Confianza	Perfiles
Alta	150
Media	169
Baja	657

4.3. Por liga y fuente

Liga	Acta	Estimada	Prensa	Atlètic	Egara	RC Polo
DHA	31	309	6	18	18	17
DHB	33	468	0	0	15	0
Primera Andaluza	0	24	0	0	0	0

> La tabla no incluye las columnas de Mundo Deportivo (4), EuroHockey (3), GSA (2), Diari de Terrassa (2), Canarias7 (1), CAH (1), 8SPORTS.es (1), University of Pretoria (1), Deporte de la Isla (19), Deporte Alicante (1), El Castillo de San Fernando (1) ni Web oficial CD Giner de los Ríos (1); están contabilizadas en la tabla 4.1.

4.4. Huecos conocidos

- **Primera Andaluza:** 4 posiciones oficiales y 24 estimadas. La cobertura sigue siendo baja; la mayoría de la plantilla no tiene posición oficial.

- **Defensas genéricos:** 399 de los 400 defensas tienen subposición Central/Lateral estimada; solo uno tiene lateral explícito.
- **Invitados:** 467 perfiles no son plantilla oficial; su posición y atributos son más inciertos.
- **Bajas:** 14 perfiles tienen fecha de baja; se mantienen para contexto histórico.

---

5. Estructura de archivos

5.1. `tools/todos_manifest_positions.csv`

Base de 976 perfiles. Columnas principales:

Columna	Contenido
`liga`	DHA, DHB, 1ª Andaluza.
`equipo`	Nombre de competición.
`club`	Nombre completo del club.
`perfil`	Jugador o Invitado.
`jugador`	Nombre.
`edad`	Edad.
`goles`	Goles iSquad (puede ser “-”).
`fecha_baja`	Fecha de baja, si existe.
`pos`	Posición base.
`src`	Fuente de la posición.
`conf`	Confianza.
`archivo_thumb`	Archivo de imagen.

5.2. `tools/player_attributes_v2.csv`

Salida del modelo. Columnas nuevas:

- `position_group`, `subposicion`, `sub_estimada`.
- `archetype`, `overall`, `potential`, `value`, `polivalencia`.
- `overall_portero`, `overall_central`, `overall_lateral`, `overall_medio`, `overall_delantero`.
- `attr_*`: 37 atributos.
- `team_specialists`: JSON con los 10 roles del equipo.

5.3. `jugadores_atributos_2026_27.csv`

Versión legible para Excel/CSV:

- Datos base.
- Posición y grupo.
- Overall, potencial, valor.
- 37 atributos con etiquetas.
- Especialistas.

5.4. Excel

`equipos_hockey_hierba_espana_masculino_2026_27_con_atributos.xlsx`:

Hoja	Contenido
Equipos únicos	Clubes y equipos.
Jugadores DHA	Plantilla con posiciones, overall y especialistas.
Jugadores DHB	Ídem.
San Fernando 1ª Andaluza	Ídem.
Resumen plantillas	Agregados por equipo.
Cobertura posiciones	Fuentes y cobertura.
Filiales excluidos	Equipos descartados.
Resumen por liga	Equipos y filiales.
Fuentes	Fuentes generales.
Notas	Notas del proyecto.
Notas jugadores	Notas de datos.
Atributos	976 filas × 37 atributos.
Especialistas	29 equipos × 10 roles.
Equipos atributos	Medias por equipo y categoría.
Diccionario atributos	Definición de cada atributo.
Cobertura atributos	Cobertura y limitaciones.
Fuentes atributos	Fuentes del modelo.

---

6. Reproducibilidad

```
cd /home/daniel/hockey_espana/tools

python3 build_attributes_v2.py
python3 generate_game.py
python3 build_excel_attributes.py
```

Dependencias

- Python 3.
- pandas.
- numpy.
- openpyxl.
- Selenium + Chromium (solo para pruebas).

Semilla

`build_attributes_v2.py` usa una semilla determinista por jugador, equipo y versión:

```
hashlib.md5((jugador + '|' + equipo + '|v2').encode()).hexdigest()
```

Si se cambia el orden de los atributos o se añaden draws aleatorios, los valores cambian. Hay que regenerar todo el pipeline.

---

7. Calidad del dato

7.1. Puntos fuertes

- Cobertura completa de 976 perfiles.
- 29 equipos únicos.
- Imágenes para todos.
- Formato de liga real.
- Atributos específicos de hockey.
- Especialistas de set pieces.
- Editor para corregir.

7.2. Puntos débiles

- 86 % de posiciones estimadas.
- 399 subposiciones estimadas.
- Sin datos oficiales de asistencias, PC, strokes o paradas.
- Sin minutos jugados.
- Sin lesiones/sanciones.
- Sin altura/peso.
- Sin datos de categorías inferiores.
- Sin hockey femenino.

7.3. Cómo mejorar

1. Validar manualmente los 175 perfiles oficiales.
2. Revisar los 400 defensas con subposición estimada.
3. Buscar actas con posición detallada.
4. Añadir datos de PC y strokes de crónicas o video.
5. Incorporar altura/peso de fichas oficiales.
6. Añadir minutos y participaciones.
7. Contrastar con entrenadores/clubes.

---

8. Privacidad y uso

- Los datos son de fuentes públicas (RFEH, clubes, prensa).
- Las imágenes se usan para identificación deportiva en un proyecto personal/educativo.
- No se publican datos sensibles.
- Si el proyecto se hace público, revisar derechos de imagen y condiciones de uso de las fuentes.

- Citar siempre la fuente y la fecha de corte.

9. Fecha de corte

- Datos de plantillas y goles: octubre de 2026.
- Clasificaciones: provisionales a 19/10/2026.
- Reglamento: circular 2026-27.
- Atributos: modelo v2, generado el 19/10/2026.

10. Fuentes citadas

- RFEH: https://www.rfeh.es/
- RFEH/iSquad: datos de competición.
- FIH: https://www.fih.hockey/
- Atlètic Terrassa: web oficial.
- Club Egara: web oficial.
- RC Polo: web oficial.
- Egara 1935: web oficial.
- Diari de Terrassa: prensa.
- Wikipedia: *Field hockey*, *Penalty corner*.
- Informes del proyecto:
- `informe_sistema_ligas_DHA_DHB_2026_27.md`
- `informe_posiciones_DHA_DHB_2026_27.md`

> Las URLs y la disponibilidad de las fuentes pueden cambiar. Guardar una copia o captura de las páginas clave si se necesita auditar el proyecto en el futuro.